

bk-crawlee 仕様書

Node.js向けWebスクレイピング & ブラウザ自動化ライブラリ

 github.com/BKStock/bk-crawlee

バージョン: v3.16.0 | ライセンス: Apache 2.0

エンドツーエンドのスクレイピング基盤

bk-crawlee 仕様書 | Slide 2

Crawleeは、Apify社が開発したオープンソースのWebスクレイピング & ブラウザ自動化ライブラリです。bk-crawleeはそのフォークリポジトリであり、最新のmasterブランチと同期しています。

 JavaScript / TypeScript (TS 59.4%)

 HTTP通信とヘッドレスブラウザの統一インターフェース

 ボット検知を回避する「人間らしい」振る舞い

 AI / LLMs / RAG 向けのデータ抽出対応



Node.js 16+

Runtime



TypeScript

Type Safe



AI Ready

GPTs / RAG



Multi-Format

HTML / PDF / IMG



Anti-Blocking

Fingerprint Generation

モノレポ構成とパッケージ管理

bk-crawlee 仕様書 | Slide 3

bk-crawleeはLernaベースのモノレポ構成を採用しており、packagesディレクトリ配下に18のサブパッケージが存在します。

Lerna

Turborepo

Vitest

カテゴリ	パッケージ名	役割
統合	crawlee	全パッケージを統合エクスポート（推奨エントリーポイント）
コア	core / types / utils	共通基盤（AutoscaledPool, SessionPool, Storage等）、型定義、ユーティリティ
CLI	cli	プロジェクト生成・管理ツール
HTTP	basic-crawler	基本クローラー実装（全クローラーの基底）
HTTP	http-crawler	HTTP通信ベースのクローラー
HTTP	cheerio-crawler	Cheerio HTMLパーサー統合（高速・軽量）
HTTP	jsdom-crawler / linkedom-crawler	JSDOM / LinkeDOM 統合（DOM操作対応）
ブラウザ	browser-crawler	ブラウザクローラー基盤
ブラウザ	browser-pool	ブラウザインスタンスプール管理（ライフサイクル管理）
ブラウザ	playwright-crawler	Playwright統合（モダンブラウザ自動化）
ブラウザ	puppeteer-crawler	Puppeteer統合（Chrome自動化）
AI	stagehand-crawler	AI搭載ブラウザ自動化（Stagehand連携・自然言語操作）

クローラーの階層構造

bk-crawler 仕様書 | Slide 4



BasicCrawlerが提供する共通機能:

📋 リクエストキュー管理

👤 自動スケーリング

👤 セッション管理

🔄 エラーハンドリング・リトライ

コアモジュールの5大機能

bk-crawlee 仕様書 | Slide 5



AutoscaledPool

システムのCPU・メモリ使用率を監視し、並行タスク数を1~200の範囲で自動調整します。

Snapshotter

SystemStatus

Auto-Scaling



SessionPool

最大1,000セッションをプール管理し、Cookieや認証状態を保持。ブロックされたセッションは自動的にローテーションされます。



ProxyConfiguration

カスタムプロキシURLのローテーション、階層型プロキシ（Tiered）、動的URL生成関数をサポートし、IPブロックを回避します。



Storage

データの永続化とキュー管理を担当する3つの主要コンポーネント。

Dataset

テーブルデータ保存 (JSON/CSV)

KeyValueStore

任意のファイル・データ保存

RequestQueue

URL管理 (幅優先/深さ優先)



Router

リクエストラベルに基づいてハンドラを振り分ける仕組み。デフォルトハンドラとラベル別ハンドラを定義可能。

HTTPクロールのボット検知回避

bk-crawlee 仕様書 | Slide 6



HTTP/2 & Proxy

ゼロコンフィグでHTTP/2をサポート。
プロキシ経由でも自動的に最適化され、
高度な通信パターンを実現。



Header Generator

ブラウザライクなHTTPヘッダーを自動生成。
User-AgentやAccept言語などを
自然な組み合わせで設定。



TLS Fingerprinting

ブラウザ固有のTLSフィンガープリントを複製。
JA3/JA4シグネチャによる
ボット検知を回避。

>_ impit-client

impit 라이브라리를 이용한 HTTP 클라이언트実装。ブラウザのリクエスト挙動を精密に模倣し、ボット検知を回避します。

Browser Impersonation

LRU Cache

TCP Reuse

High Performance

</> HTML Parsers

パーサー	特徴	用途
Cheerio	高速・軽量、jQuery風API	静的HTML解析に最適
JSDOM	完全なDOM実装	DOM操作が必要な場合
LinkeDOM	高速なDOM実装	JSDOMの軽量代替

ブラウザクロールの統一インターフェース

bk-crawlee 仕様書 | Slide 7



Unified API Surface



PlaywrightCrawler



PuppeteerCrawler



Chrome



Firefox



WebKit

★ 主要機能

- ▶ **統一インターフェース:** Playwright / Puppeteer を同一コードで操作可能
- ▶ **マルチブラウザ:** Chrome, Firefox, WebKit, Edge 等に対応
- ▶ **モード切替:** ヘッドレス（高速） / ヘッドフル（デバッグ）を即座に切替
- ▶ **ボット対策回避:** 人間らしいフィンガープリントをゼロコンフィグで自動生成
- ▶ **Cloudflare対応:** チャレンジ認証の自動処理機能を搭載

≡ browser-pool の役割

- ▶ **ライフサイクル管理:** ブラウザインスタンスの起動・終了・再起動を自動化
- ▶ **ページ管理:** ページの作成・破棄、クラッシュ時の自動回復
- ▶ **プロキシ匿名化:** 接続ごとのプロキシ適用と匿名化処理
- ▶ **フィンガープリント注入:** Pre-Launch / Post-PageCreate フックによる指紋偽装
- ▶ **プラグイン拡張:** カスタムフックによる機能拡張

AI搭載の自然言語ブラウザ自動化

bk-crawlee 仕様書 | Slide 8

⚡ v3.16.0 New Feature: @crawlee/stagehand (Powered by Browserbase Stagehand)

page.act(instruction)

自然言語でブラウザ操作を指示

```
await page.act('Click the login button');
```

page.extract(instruction, schema)

Zodスキーマに基づいた型安全な構造化データ抽出

```
await page.extract('Get price', z.object({ price: z.number() }));
```

page.observe()

ページ上の操作可能な要素をAIが分析・提案

```
const actions = await page.observe();
```

page.agent(config)

対応AIモデル

OpenAI (gpt-4.1-mini)

Anthropic (Claude)

Google Gemini

実行環境 (env)

🖥️ LOCAL: ローカルブラウザ + APIキー

☁️ BROWSERBASE: クラウドブラウザ環境

主な設定オプション

- ✓ selfHeal (エラー自動回復)
- ✓ domSettleTimeout (DOM安定化待機)
- ✓ systemPrompt (カスタムプロンプト)

開発フローと実行環境

bk-crawlee 仕様書 | Slide 9

>_ インストール

CLI (Recommended)

```
npx crawlee create my-crawler  
cd my-crawler && npm start
```

Manual

```
npm install crawlee playwright
```

≡ プロジェクトテンプレート (11種)

cheerio-js / ts

playwright-js / ts

puppeteer-js / ts

getting-started-js / ts

empty-js / ts

camoufox-ts

🗄 データ保存 (./storage)



Dataset

JSON / CSV



KeyValueStore

Any File



RequestQueue

URL Management

🚀 デプロイメント



Docker Support

各テンプレートにDockerfileが同梱。
Base Image: apify/actor-node:20



Apify Platform

Apify SDKと連携し、クラウド上での実行・スケジューリング・監視が可能。

技術スタックと全体像

bk-crawlee 仕様書 | Slide 10

Languages & Runtime

TypeScript

JavaScript

Node.js 16+

Monorepo & Build

Lerna

Turborepo

Yarn Workspaces

Testing & Quality

Vitest

ESLint

Biome

Browser Automation

Playwright

Puppeteer

Stagehand (AI)

HTML Parsing

Cheerio

JSDOM

Linkedom

Infrastructure

Docker

GitHub Actions

Apify SDK

5,206

COMMITTS

54

BRANCHES

645

TAGS

v3.16.0

LATEST VERSION

✔️ bk-crawleeの強み

- ✔️ HTTPからブラウザまで統一されたAPIで、多様なスクレイピングニーズに柔軟に対応
- ✔️ ボット検知回避機能がデフォルトで組み込まれており、追加設定なしで安定稼働
- ✔️ 自動スケーリング・セッション管理・プロキシローテーションによる堅牢な運用基盤
- ✔️ AI搭載のStagehandCrawlerにより、自然言語でのブラウザ操作が可能
- ✔️ モノレポ構成により、必要なパッケージのみを選択的に利用可能

💡 推奨ユースケース

- 🗄️ **大規模Webデータ収集**
商品情報、価格監視、ニュース収集など
- 📄 **動的サイトのスクレイピング**
JavaScriptレンダリングが必須なSPAサイト
- 🧠 **AI構造化データ抽出**
LLMを活用した非構造化データの解析
- ☁️ **定期実行クローラー**
Docker / クラウドデプロイによる自動化